

MODUL 3

Sayyid Quthub

9/16/2021

C. Dasar Teori

Variasi tipe data pada R memfasilitasi keberagaman jenis variabel data. Sebagai contoh, terdapat data yang terdiri dari sekumpulan angka dan data lain yang berisi sekumpulan karakter. Pada contoh lain, ada pula data yang berbentuk tabel maupun kumpulan (list) angka sederhana. Dengan bantuan fungsi `class`, kita akan mendapatkan kemudahan dalam mendefinisikan tipe data yang kita miliki: `a <- 2 class(a) #> [1] "numeric"`

Agar dapat bekerja secara efisien dalam menggunakan bahasa pemrograman R, penting untuk mempelajari terlebih dahulu tipe data dari variabel-variabel yang kita miliki sehingga akan mempermudah dalam penentuan proses analisis data yang dapat dilakukan terhadap variabelvariabel tersebut.

Data Frames

Cara paling umum yang dapat digunakan untuk menyimpan dataset dalam R adalah dalam tipe data frame. Secara konseptual, kita dapat menganggap data frame sebagai tabel yang terdiri dari baris yang memiliki nilai pengamatan dan berbagai variabel yang didefinisikan dalam bentuk kolom. Tipe data ini sangat umum digunakan untuk dataset, karena data frame dapat menggabungkan berbagai jenis tipe data dalam satu objek. Untuk memahami tipe data frame, silahkan mengakses contoh dataset pada `library(dslabs)` dan pilih dataset "murders" menggunakan fungsi `data`: Untuk memastikan bahwa dataset tersebut tipenya adalah data frame, dapat digunakan perintah berikut: Untuk memeriksa lebih lanjut isi dataset, dapat pula digunakan fungsi `str` untuk mencari tahu lebih rinci mengenai struktur suatu objek: `str(murders)`

Dengan menggunakan fungsi `str`, dapat diketahui bahwa dataset "murders" terdiri dari 51 baris dan lima variabel: `state`, `abb`, `region`, `population`, dan `total`. Selanjutnya, untuk melihat contoh enam baris pertama pada dataset, dapat digunakan fungsi `head`: Untuk analisis awal tiap variabel yang diwakili dalam bentuk kolom pada tipe data frame, dapat digunakan operator aksesori `()` dengan cara berikut: `murders$population`

Untuk mengetahui nama-nama dari lima variabel yang dapat dievaluasi menggunakan operator aksesori, sebelumnya, melalui fungsi `str`, telah kita ketahui bahwa variabel yang dimiliki dataset adalah: `state`, `abb`, `region`, `population`, dan `total`. Sebagai alternatif, terdapat pula fungsi `names`, yang dapat digunakan seperti contoh dibawah ini: `names(murders)`

Vector : numeric, character, dan logical

Objek `murders$population` terdistribusi ke kumpulan `numeric` data — *data angka*. Sehingga, kita dapat mendefinisikan bahwa tipe data `murders$population` berupa vector. Angka tunggal secara teknis dapat didefinisikan sebagai vektor dengan panjang 1, tetapi secara umum kita akan menggunakan vector sebagai istilah untuk merujuk ke objek yang terdiri dari beberapa entri. Untuk mengidentifikasi banyaknya entri dalam suatu vector dapat digunakan fungsi `length` seperti contoh berikut:

```
length(murders$population)
```

Vector khusus ini bertipe `numeric` karena populasi terdiri dari data-data angka:

```
class(murders$population)
```

Secara matematis, nilai-nilai dalam `murders$population` adalah berupa integer. Namun, secara default, data angka akan diberikan tipe `numeric` meskipun sebenarnya data tersebut merupakan bilangan bulat. Misalnya, `class(1)` akan mengidentifikasi nilai 1 sebagai tipe `numeric`. Untuk mengubah tipe `numeric` menjadi integer, dapat digunakan fungsi `as.integer()` atau dengan menambahkan `L` pada akhir data angka, contoh: `1L`. Untuk melihat perbedaannya, silahkan gunakan `class(1L)`. Vector juga dapat digunakan untuk menyimpan string dengan tipe `character`, Sebagai contoh:

```
nama negara pada dataset "murders": class(murders$state)
```

Jenis vector penting lainnya adalah `logical` yang nilainya berupa `TRUE` atau `FALSE`. `z <- 3 == 2`

```
class(z)
```

##Factors Dalam dataset "murders", variabel `state` yang berisi data karakter bukan bertipe vector: `character`, namun, tipe datanya adalah `factor`: `class(murders$region)`

Faktor berguna untuk menyimpan data kategorikal. Dapat dilihat, bahwa hanya terdapat 4 wilayah pada variabel `state`. Untuk melihat jumlah kategori yang dimiliki oleh variabel dengan tipe data `factor` dapat digunakan fungsi `level`: `levels(murders$region)`

Pada background process, R menyimpan `level` sebagai bilangan bulat yang memiliki peta tersendiri untuk melacak arti label dari bilangan tersebut. Hal ini dimaksudkan untuk penghematan memori, terutama apabila karakter dari tiap `level` cukup panjang. Standarnya, `level` akan ditampilkan sesuai urutan abjad.

##Lists Data frame merupakan sekumpulan list yang memiliki kelas yang berbeda-beda. Sama halnya dengan data frame, analisis list dapat dilakukan dengan menggunakan operator aksesor (`$`) dan dua kurung siku (`[]`). ##Matriks Matriks merupakan tipe data yang mirip dengan data frame karena keduanya memiliki dua dimensi, yaitu: baris dan kolom. Namun, sama halnya dengan tipe data vector numerik, karakter dan logis, entri dalam matriks harus terdiri dari jenis vector yang sama. Dalam hal ini, data frame dapat dikatakan sebagai tipe data yang paling cocok untuk menyimpan data, karena kita dapat memiliki karakter, faktor, dan angka sekaligus dalam satu data frame. Namun matriks memiliki satu keunggulan yang tidak dimiliki oleh tipe data frame: pada matriks dapat

dilakukan operasi aljabar. Untuk mendefinisikan matriks, dapat digunakan fungsi `matrix` dengan mendefinisikan pula argumen berupa jumlah baris dan kolom yang diinginkan. `mat <- matrix(1:12, 4, 3)` `mat`

Untuk mengakses entri tertentu dalam matriks, dapat digunakan tanda kurung siku (`[]`). Sebagai contoh, kita akan menampilkan data pada baris kedua, kolom ketiga, menggunakan: `mat[2, 3]`